

RETINAL OCT IMAGES


OPTICAL COHERENCE TOMOGRAPHY

GRUPO 9 - TURINGS

Alexandre Béo da Cruz
Felipe Cesar Silva
Fellipe Souto Sampaio
Max Dias Saito
Vinicius Nascimento Aguiar



MINERAÇÃO DE
DADOS COMPLEXOS
TRABALHO FINAL



**Instituto de
Computação**

UNIVERSIDADE ESTADUAL DE CAMPINAS



Agenda

- Introdução
- Análise e Tratamento
- Modelo Baseline
- Base Honesta
- Explicabilidade, Novo Tratamento e Aumentação
- Resultado Final
- Avaliações no Teste



Introdução

Problema, motivação e objetivo

Doenças Oculares

Quase **10 milhões** de pessoas sofrem de degeneração macular relacionada à idade nos EUA ¹




Figura: Olho esquemático.³

A cada ano mais de **200.000 pessoas** desenvolvem neovascularização de coróide ¹

E **750.000 pessoas** com 40 ou mais anos sofrem de edema macular diabético ²

1. Ferrara, 2010; Friedman et al., 2004; Wong et al., 2014

2. Varma et al., 2014

3. <https://www.clinicadeolhoserechim.com.br/retinografia/>

Tomografia de Coerência Óptica (OCT)

Tomografia de coerência óptica (OCT) é uma técnica que captura imagens de alta resolução de diversas seções da retina de pacientes vivos. Frequentemente utilizada para detectar as principais doenças causadoras de cegueira.

- Neovascularização da coróide na degeneração macular relacionada à idade (**CNV**)
- Edema macular diabético (**DME**)
- Drusas oculares (**DRUSEN**)
- Retina normal com contorno foveal preservado e ausência de qualquer fluido retinal (**NORMAL**)




Figura: Possíveis resultados da OCT¹



Análise e Tratamento

Limpeza, distribuição, adequação
e visualização dos dados

Sumário

Problema

Classificação multiclasse
com desbalanceamento

Categorias

CNV, DME, DRUSEN e NORMAL

Base

84.494 imagens

Imagens

Formato JPEG, sem padrão de
resolução e com rotações



Pacientes

Identificado por ID, podem ter mais
de uma imagem da mesma ou de
diferentes categorias.



Divisão

Possui treino/validação/teste. No
entanto **um mesmo paciente pode
estar em mais de um conjunto.**

Divisão original da base



Nova divisão da base 80/20



Tratamento das Imagens




Figura: Conversão de canais da imagem e normalização no intervalo $[0,1]^1$




Figura: Distribuição das resoluções no Dataset

	shape_ax0	shape_ax1	fracao
0	496	384	0.000189
1	496	512	0.457613
2	496	768	0.257031
3	496	1024	0.003243
4	496	1536	0.098977
5	512	512	0.182946




Figura: Processo de resize


1. https://e2eml.school/convert_rgb_to_grayscale.html



Modelo Baseline

Transfer Learning da ResNet50V2 - Arquitetura Base

- Peso: Imagenet
- Ativação Softmax e Otimizador Adam (learning rate de 0.001)
- Tamanho do Batch: 32
- Função de Custo: Entropia Cruzada Categórica




Legendas

Bloco convolucional
($n \times n, k$) onde
 k - Filtro de tamanho k
 n - Num. de canais

DRF - Deep Residual Feature

Transfer Learning da ResNet50V2 - Nossa adaptação

- Peso: Imagenet
- Ativação Softmax e Otimizador Adam (learning rate de 0.001)
- Tamanho do Batch: 32
- Função de Custo: Entropia Cruzada Categórica




Legendas

Bloco convolucional
($n \times n, k$) onde
 k - Filtro de tamanho k
 n - Num. de canais

DRF - Deep Residual Feature


Resultados do Transfer Learning

Treinamento



Acurácia Balanceada: 90.7%

Validação





Acurácia Balanceada: 88.8%




Base Honesta

Separação de pacientes para uma
representação honesta do problema

Distribuição de imagens por paciente




Divisão honesta 80/20 por pacientes




Resultados com a base “honesta” modelo baseline

Treinamento



Acurácia Balanceada: 90.3%

Validação




Acurácia Balanceada: 80.3%




Explicabilidade
Novo Tratamento
Aumentação de dados


Probs: [0.0, 0.01, 0.0, 0.99]




Label: NORMAL




Predição: NORMAL




Probs: [0.01, 0.62, 0.09, 0.29]




Label: NORMAL




Predição: DME




Probs: [0.0, 1.0, 0.0, 0.0]



Label: DME




Predição: DME




Tratamento de bordas

Sem Tratamento:


DRUSEN




DME




CNV



CNV




CNV




Com Tratamento:


DRUSEN




DME




CNV



CNV




CNV




Aumentação de dados

- Rotação
- Translação vertical
- Zoom
- Espelhamento horizontal

Conjunto de Treino:




Conjunto de Validação:





Resultado Final


Comparativo de performance de diferentes redes neurais



Rede	Treino	Validacao
ResNet50V2 (Baseline)	0.903	0.803
ResNet101V2	0.880	0.795
Xception	0.842	0.761
InceptionResNetV2	0.830	0.736
Autoencoder (Treinado)	0.370	0.360

Transfer Learning da ResNET50 - Otimizado

- Peso: Imagenet
- Ativação Softmax e Otimizador SGD (learning rate de 0.0001)
- Tamanho do Batch: 32
- Função de Custo: Entropia Cruzada Categórica
- Tratamento de bordas
- Data Augmentation
- Mais camadas densas




Legendas

Bloco convolucional
(n x n, k) onde
k - Filtro de tamanho k
n - Num. de canais


DRF - Deep Residual Feature

Transfer Learning da ResNET50 - Otimizado




Resultado Final

Treinamento



Acurácia Balanceada: 93.9%

Validação




Acurácia Balanceada: 87.2%



Avaliações no Teste


Teste

Baseline



Acurácia Balanceada: 95.1%


Modelo Final



Acurácia Balanceada: 93.9%


Teste Complementar

Baseline



Acurácia Balanceada: 87.5%



Modelo Final




Acurácia Balanceada: 87.2%

Mudanças no CAM


Predição: NORMAL




Probs: [0.0, 0.03, 0.0, 0.97]





Label: NORMAL




Predição: NORMAL




Predição: DME




Probs: [0.02, 0.04, 0.16, 0.79]





Label: NORMAL




Predição: NORMAL




Predição: DME




Probs: [0.01, 0.4, 0.0, 0.58]



Label: DME



Predição: NORMAL





Obrigado

Deploy WebApp: <https://bit.ly/mdc009-turings>



RETINAL OCT IMAGES

OPTICAL COHERENCE TOMOGRAPHY

GRUPO 9 - TURINGS

Alexandre Béo da Cruz

Felipe Cesar Silva

Fellipe Souto Sampaio

Max Dias Saito

Vinicius Nascimento Aguiar




Etapas da análise

- Leitura do dataset direto do Kaggle
- Criação de dataframe para avaliação do conteúdo das pastas
- Verificação da quantidade de imagens
- Verificação de consistência entre labels da pasta e do arquivo
- Verificação da quantidade de pacientes
- Verificação de exclusividade dos pacientes no dataset de teste
- Verificação do balanceamento de classes
- Divisão das imagens em treino e validação respeitando a distribuição original (desbalanceada)
- Definição de pesos para balanceamento das classes


Base Original

Divisão


< test (4 directories)



< train (4 directories)




< val (4 directories)



Rotulagem

(doença)-(código de identificação do paciente)-(número da imagem)



Paciente 53018

Paciente 81630

Otimização da solução

- Re-treinar a rede com um pré-processamento das imagens mais sofisticado
- Descongelar mas camadas e treinar para o dataset específico
- Testar outros classificadores
 - SVM
 - Árvores de Decisão

Interpretabilidade do modelo com CAM e GradCAM

